

교과목 2 : 데이터 분석과 머신러닝 / 딥러닝

단원 2 : 머신러닝

DAY7. 머신러닝 비지도학습 알고리즘

목 차

1. 비지도학습이란?		3
2. 비지도학습 알고리즘 종류		5
3. 연관 규칙 분석 알고리즘		15
4. 클러스터링 알고리즘		22

1. 비지도학습이란?

비지도학습(Unsupervised Learning)은 정답(Label)이 없는 데이터를 이용하여 데이터 내부에 숨어 있는 패턴(Pattern), 구조(Structure), 관계(Relationship)를 스스로 찾아내는 머신러닝 기법이다.

지도학습(Supervised Learning)은 "정답이 있는 문제"를 학습하지만, 비지도학습은 정답 없이 데이터만 주어진 상태에서 데이터의 특성과 유사성을 분석하여 의미 있는 정보를 발견하는 것이 목적이다.

예를 들어 고객 데이터가 있다고 가정하자.

고객번호	나이	구매금액
A	20	50만원
B	22	45만원
C	55	300만원
D	58	280만원

비지도학습은 다음과 같은 질문에 답한다.

- 어떤 고객들이 비슷한가?
- 고객 그룹은 몇 개로 나눌 수 있는가?
- 이상한 데이터는 존재하는가?
- 데이터의 주요 특징은 무엇인가?

즉, 데이터를 스스로 분석하여 구조를 찾아내는 학습 방법이다.

1) 비지도학습의 주요 목적

비지도학습은 크게 다음 목적을 가진다.

① 군집화(Clustering)

비슷한 데이터끼리 그룹으로 묶음
예)

- 고객 세분화
- 상품 추천
- 사용자 행동 분석

② 차원 축소(Dimensionality Reduction)

많은 특성을 적은 특성으로 압축

예)

- 데이터 시각화
- 노이즈 제거
- 학습속도 향상

③ 연관 규칙 분석(Association Rule Learning)

함께 발생하는 패턴 발견

예)

- 장바구니 분석
- 추천 시스템

④ 이상치 탐지(Anomaly Detection)

정상 패턴에서 벗어난 데이터 발견

예)

- 신용카드 부정 사용
- 네트워크 침입 탐지

2. 비지도학습 알고리즘 종류

1. 군집화 (Clustering)

가장 대표적인 비지도학습이다.

목표는 다음과 같다.

*비슷한 데이터는 같은 그룹으로,
다른 데이터는 다른 그룹으로 분류*

(1) K-Means

가장 많이 사용되는 군집화 알고리즘

작동 과정

1. K개의 중심점(Centroid) 선택
2. 각 데이터를 가장 가까운 중심점에 배정
3. 군집 평균 계산
4. 중심점 이동
5. 반복

목적 함수

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

여기서

- k : 군집 개수
- C_i : 군집
- μ_i : 군집 중심

목표는 각 데이터와 중심점 사이 거리를 최소화하는 것이다.

장점

- 구현 쉬움
- 계산 빠름

단점

- K를 미리 지정해야 함
- 이상치에 민감

(2) 계층적 군집화 (Hierarchical Clustering)

데이터를 트리 구조로 군집화

종류

Agglomerative

아래에서 위로

데이터 → 소규모 군집

→ 큰 군집

→ 최종 군집

Divisive

위에서 아래로

전체 데이터

↓



군집 분할






↓

세부 군집

결과

Dendrogram(덴드로그램)





트리 형태로 군집 관계를 확인할 수 있다.

(3) DBSCAN

밀도 기반 군집화

Density-Based Spatial Clustering of Applications with Noise

핵심 개념

반경 ϵ (Epsilon) 안에 충분한 데이터가 존재하면 같은 군집으로 판단

파라미터

- ϵ (Epsilon)
- MinPts

특징

장점

- 군집 개수 지정 불필요
- 이상치 자동 탐지

단점

- 파라미터 설정 어려움

2. 차원 축소(Dimensionality Reduction)

고차원 데이터를 저차원 데이터로 압축하는 기술

예)

100개 특성

↓

10개 특성

↓

2개 특성

(1) PCA (Principal Component Analysis)

가장 대표적인 차원 축소 기법

핵심 아이디어

데이터 분산이 가장 큰 방향을 찾는다.

그 방향을 주성분(Principal Component)이라고 한다.

과정

1단계

평균 제거

$$X_{centered} = X - \mu$$

2단계

공분산 행렬 계산

$$Cov(X) = \frac{1}{n-1} X^T X$$

3단계

고유값(Eigenvalue) 분해

$$Av = \lambda v$$

4단계

큰 고유값의 고유벡터 선택

결과

원본 : 100차원

↓

PCA

↓

2차원

활용

- 데이터 시각화
- 노이즈 제거
- 특징 추출

(2) t-SNE

고차원 데이터를 2차원 또는 3차원으로 변환

장점

- 시각화 성능 우수

단점

- 계산량 많음

(3) UMAP

최근 많이 사용되는 차원 축소 기법

장점

- PCA보다 구조 보존
- t-SNE보다 빠름

3. 연관 규칙 분석

장바구니 분석(Market Basket Analysis)

예)

빵 → 우유


맥주 → 기저귀

대표 알고리즘

Apriori

지지도(Support)

전체 거래 중 해당 항목이 등장한 비율



신뢰도(Confidence)

A 구매 시 B 구매 확률

$$Confidence(A \rightarrow B) = \frac{P(A \cap B)}{P(A)}$$

향상도(Lift)

독립일 때보다 얼마나 함께 구매되는지

$$Lift(A \rightarrow B) = \frac{P(A \cap B)}{P(A)P(B)}$$

Lift 해석

Lift	의미
=1	독립
>1	양의 상관관계
<1	음의 상관관계

4. 이상치 탐지(Anomaly Detection)

정상 데이터와 다른 데이터를 찾는 방법

예)

- 카드 도용
- 해킹
- 센서 고장

(1) Isolation Forest

이상치를 쉽게 분리할 수 있다는 개념 사용

특징

- 빠름
- 대용량 처리 가능

(2) One-Class SVM

정상 데이터만 학습


정상 영역 밖 데이터를 이상치로 판단

5. Autoencoder

딥러닝 기반 비지도학습

입력을 스스로 복원하도록 학습

구조



손실 함수

입력과 출력 차이를 최소화

$$MSE = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2$$

활용

- 차원 축소
- 이미지 압축
- 이상치 탐지
- 생성형 AI 기초 기술

비지도학습 알고리즘 비교

알고리즘	목적	대표 활용
K-Means	군집화	고객 세분화
Hierarchical	군집화	유전자 분석
DBSCAN	군집화	위치 데이터
PCA	차원 축소	특징 추출
t-SNE	시각화	데이터 분석
UMAP	시각화	대용량 데이터
Apriori	연관 규칙	장바구니 분석
Isolation Forest	이상치 탐지	금융 사기 탐지
Autoencoder	딥러닝 비지도학습	이미지 압축

비지도학습은 정답(Label)이 없는 데이터를 분석하여 숨겨진 구조와 패턴을 발견하는 머신러닝 기법이다. 대표적으로 군집화(K-Means, DBSCAN), 차원 축소(PCA, t-SNE, UMAP), 연관 규칙 분석(Apriori), 이상치 탐지(Isolation Forest), 딥러닝 기반 Autoencoder가 있다.

실제 산업 현장에서는 고객 세분화, 추천 시스템, 의료 데이터 분석, 금융 사기 탐지, 제조 공정 이상 감지, AI 데이터 전처리 등 다양한 분야에서 활용되고 있으며, 최근에는 생성형 AI의 데이터 표현 학습과 RAG 시스템의 벡터 임베딩 생성 과정에서도 비지도학습 개념이 핵심적으로 사용되고 있다.

3. 연관 규칙 분석 알고리즘

패턴 찾기로 연관된 규칙과 구매빈도 분석

연관 규칙 학습으로 알고리즘 적용하기

1. 연관 규칙의 이해

1) 분석의 기본

- 항목 : 장바구니 분석의 기본 구성 단위
- 항목 집합 : 규칙성을 포함하고, 데이터로 표현됨
- 장바구니 분석 결과 : 연관 규칙의 모음인 항목 집합 간의 관계에 존재하는 패턴 명시

2) 연관 규칙 학습 알고리즘

- 아프리오리(apriori) 알고리즘

- * 특정한 두 아이템 집합이 자주 발생하는 것에 대한 가능성을 알려주는 일련의 규칙 생성에 필요한 알고리즘
- * 거래 데이터 셋 활용
- * 모니터링 되는 항목 또는 특징의 개수, 거래 횟수는 큼
- * 항목 집합의 개수가 특징적인 개수에 따라 문제가 기하급수적으로 증가

3) 아프리오리(apriori) 알고리즘의 장점

- 대규모 거래 데이터의 작업 가능
- 이해하기 쉬운 규칙 생성
- 데이터마이닝과 데이터베이스에서 생각하지 못한 지식 발견

4) 아프리오리(apriori) 알고리즘의 단점

- 작은 데이터 셋에는 유용하지 않음
- 통찰과 상식의 분리에 적합한 노력 필요
- 랜덤 패턴에서 결론을 도출하기 쉬움

연관 규칙 학습으로 알고리즘 적용하기

2. 연관 규칙의 측정

1) 규칙의 흥미 측정

- 지지도와 신뢰도
 - * 연관 규칙 여부는 신뢰도와 지지도 두 통계 척도에 따라 결정
 - * 각 척도에 적합한 최소 임계값 제공
 - * 아프리오리(apriori) 원칙을 적용한 후 규칙의 개수를 급격하게 제한

2) 아프리오리 규칙 집합의 원칙

- 항목 집합의 모든 부분집합이 빈번함

반복	반드시평가	빈번한아이템 집합	빈번하지않은아이템 집합
1	{A}, {B}, {C}, {D}	{A}, {B}, {C}	{D}
2	{A, B}, {A, C}, {B, C} {A, D}, {B, D}, {C, D}	{A, B}, {B, C}	{A, C}
3	{A, B, C}		
4	{A, B, C, D}		

〈아프리오리 알고리즘의아이템 집합 계산〉

3) 아프리오리 규칙 집합의 구축

- 지지도 : 항목 집합이 데이터 빈도를 나타냄
- 규칙 생성에 적합한 두 단계

❶ 최소 지지도 임계값에 적합한 모든 항목 집합 구분

❷ 최소 신뢰도 임계값에 적합한 집합으로 규칙 생성

- 최소 신뢰도 임계값에 대한 평가
 - * 원하는 신뢰도 수준에 적합하지 않은 규칙은 모두 삭제

연관 규칙으로 구매 빈도에 따른 상품 식별하기

1. 연관 규칙 식별 준비

1) 학습 연관 규칙

- 학습된 연관 규칙에 따라 식료품 체인의 재고 최적화
- 판촉 홍보 활동
- 매장의 배치 구성으로 새로운 방식에 대한 적용 및 통찰력 생성
- 식료품 매장의 거래 데이터로 장바구니 분석 수행
- 아프리오리(apriori) 알고리즘이 연관 규칙 집합을 효율적으로 평가


2) 1단계 : 분석 데이터 수집

- 한 달 동안 운영 관리한 식료품 매장의 구매 데이터 활용
- 9,835건의 거래 데이터 또는 일일 단위 약 327건의 거래 포함
- 식료품 가게에서 다양한 종류의 항목으로 반환
 - * 어떤 항목 종류가 함께 구매되는지 여부를 추측할 수 있는가?
 - * 와인과 치즈가 일반적으로 한 그룹이 될 것인가?
 - * 빵과 버터는?
 - * 차와 꿀은?
→ 다양한 종류의 항목들을 거쳐 추측 및 확인


연관 규칙으로 구매 빈도에 따른 상품 식별하기

3) 2단계 : 분석 데이터 탐색과 준비

- 거래 데이터는 자유 형식
- 각 레코드 : 1개부터 n개까지 쉼표로 구분된 임의의 개수에 대한 목록 구성




〈거래 내역에서 식료 아이템의 10% 지지도 레벨〉



〈상위 30개 식료 아이템의 지지도 레벨〉

- 거래 데이터의 희소 행렬 생성
 - * 1개 항목 : 거래가 총 2,159건
 - * 32개 항목 : 거래가 1건
 - * 구매 크기의 1사분위와 중앙값은 각각 2개와 3개 항목으로 구성
 - * 거래의 25%가 2개 이하의 항목을 포함함
 - * 해당 거래의 경우 평균 4,409 항목이 일치함
 - * 행렬 표기와 itemFrequency()함수를 활용하여 항목을 포함한 거래 비율 출력
- 거래 데이터의 희소 행렬 생성
 - * 구매 항목은 열, 구매는 행으로 검정색을 채움




〈거래 내역 희소 행렬의 시각화〉

연관 규칙으로 구매 빈도에 따른 상품 식별하기

3) 2단계 : 분석 데이터 탐색과 준비

- 항목 지지도의 시각화 : 항목 빈도 그래프
 - * 시각화 `itemFrequencyPlot()` 함수 사용
 - * 막대 차트 생성 : 특정 항목이 포함된 거래 비율 표시
 - * 8개 항목의 히스토그램(최소 10%의 지지도 포함)
 - * 상위 20개 항목의 지지도를 내림차순으로 정렬
 - * 행렬 다이어그램 : 200개의 행 + 169개의 열



(랜덤 선택 거래 최소 행렬의 시각화)

- 거래 데이터의 시각화 : 희소 행렬 도표화
 - * 전체 희소 행렬 시각화
 - * `Image()` 함수 사용
 - * 행렬 자체가 크기 때문에 전체 행렬에 대한 부분 집합 활용의 최적화

4) 3단계 : 분석 데이터 모델 훈련

- 장바구니 항목 사이의 연관성 있는 작업이 가능함
- `arules` 패키지의 아프리오리 알고리즘 구현 및 활용
- `apriori()` 함수로 규칙 집합 생성
 - * 최소 지지도의 설정 문제 : 한 패턴에 필요한 최소 거래 건수 고려
 - * 최소 신뢰도 설정은 정확한 균형 필요
 - * 신뢰도가 너무 저조할 경우 신뢰할 수 없는 규칙이 많아지게 됨
 - * 신뢰도 임계값 : 0.25
 - * 결과적으로 신뢰할 수 없는 규칙은 제거
 - * 타게팅(targeting) 홍보 활동으로 고객의 행동을 긍정적으로 변화시킬 수 있는 기회가 됨

연관 규칙으로 구매 빈도에 따른 상품 식별하기

2. 연관 규칙 식별 성능

1) 4단계 : 분석 모델 성능 평가

- 규칙의 크기 분포 : 많은 규칙이 각 개수의 항목을 포함하는지의 여부
- 규칙 집합의 150개 규칙 : 2개의 항목 포함
- 규칙 집합의 297개 규칙 : 3개의 항목 포함
- 규칙 집합의 16개 규칙 : 4개의 항목 포함
- 신뢰성 있는 규칙의 발견과 해석에 도움을 줄 수 있음
- 소매 체인 관리 분야 전문가와의 협업 필요

2) 5단계 : 분석 모델 성능 개선

- 다양한 기준에 따라 규칙 정렬
 - * **관련 마케팅팀과 공유**
 - * 세심한 검토 형태로 변환이 가능할 경우 유용함
- 연관 규칙 집합 정렬
 - * 장바구니 목적에 따른 유용한 규칙은 높은 lift, support, confidence를 포함함
 - * 품질 측정치의 최고나 최저값을 포함하는 규칙이 우선이 되도록 규칙 목록 재정렬
 - * 첫 번째 규칙(약 3.96의 lift 포함)
 - 허브를 구매한 사람이 뿌리 채소를 구매할 가능성이 뿌리 채소를 일반 고객이 구매할 가능성에 비해 약 4배 정도 높다는 것을 시사함
 - 휘핑크림이 베리와 장바구니에 함께 있을 확률이 3배 이상 높으며 디저트 그룹이 된다는 것을 시사함
- 연관 규칙의 부분 집합 계산
 - * 베리가 포함된 규칙 : 4개
 - * 베리는 휘핑크림 뿐만 아니라 요거트와 함께 구매

연관 규칙으로 구매 빈도에 따른 상품 식별하기

2) 5단계 : 분석 모델 성능 개선

- 부분 집합의 선택 조건(키워드와 연산)

- * 키워드 item은 규칙의 곳곳에서 나타나는 항목 등과 매칭함
- * 연산자 %in% 항목 중 최소 하나 이상의 정의 목록에서 발견
- * 완전 매칭(%ain%), 부분 매칭(%in%): 추가 연산자를 활용
- * 부분 집합 : support, confidence, lift로 제약
- * 매칭 조건 : AND(&), OR(|), NOT(!) 등의 논리 연산자와 결합

- 연관 규칙을 파일이나 데이터프레임에 저장

- * 규칙으로 구성된 벡터 형식의 데이터프레임
- * support, confidence, lift 수식 등의 벡터 생성
- * 규칙에 대한 추가 처리에 적합한 데이터베이스로 내보내기 필요
- * 데이터 프레임으로 저장한 후 요약

```
> # 베리 항목 영역의 규칙에 따른 하위 집합 검색하기
> shop_berryrules <- subset(shop_groceryrules, items %in%
"berries")
> # subset()로 부분 집합 찾기
> # berries 에 나타난 규칙을 검색함
> inspect(shop_berryrules) # 베리는 휘핑크림, 요거트와도 자주
구매
```

	lhs	rhs	support
[1]	{berries}	=> {whipped/sour cream}	0.009049314
[2]	{berries}	=> {yogurt}	0.010574479
[3]	{berries}	=> {other vegetables}	0.010269446
[4]	{berries}	=> {whole milk}	0.011794611

	confidence	coverage	lift	count
[1]	0.2721713	0.0332486	3.796886	89
[2]	0.3180428	0.0332486	2.279848	104
[3]	0.3088685	0.0332486	1.596280	101
[4]	0.3547401	0.0332486	1.388328	116

4. 클러스터링 알고리즘

클러스터링(Clustering)은 **정답 라벨이 없는 데이터**를 비슷한 특성을 가진 데이터끼리 자동으로 묶는 비지도학습 알고리즘이다.

예를 들어 고객 데이터에서 나이, 구매금액, 방문횟수 등의 특성을 보고 비슷한 고객끼리 묶거나, 꽃 데이터에서 꽃잎 길이와 너비가 비슷한 꽃끼리 그룹을 만드는 것이 클러스터링이다.

클러스터링의 핵심 목적은 데이터를 사람이 미리 정한 정답으로 분류하는 것이 아니라, 데이터 자체가 가지고 있는 **거리, 밀도, 분포, 유사성**을 기준으로 자연스러운 그룹을 찾는 것이다.

1. 클러스터링의 기본 개념

클러스터링에서 하나의 데이터는 보통 벡터로 표현된다.

예를 들어 어떤 꽃 데이터가 다음과 같다고 하자.

꽃 $A = [\text{꽃받침 길이}, \text{꽃받침 너비}, \text{꽃잎 길이}, \text{꽃잎 너비}]$

꽃 $A = [5.1, 3.5, 1.4, 0.2]$

이 데이터는 4 개의 숫자로 표현된 하나의 점이다. 클러스터링은 이런 점들이 공간상에서 얼마나 가까운지를 계산하여 비슷한 점끼리 묶는다.

예를 들어 꽃 A와 꽃 B가 매우 비슷한 값을 가진다면 두 데이터는 같은 군집에 속할 가능성이 높다. 반대로 꽃 A와 꽃 C의 값 차이가 크다면 서로 다른 군집에 속할 가능성이 높다.

2. 거리 계산의 기본 공식

클러스터링에서 가장 많이 사용하는 거리 공식은 **유클리드 거리(Euclidean Distance)** 이다.

두 데이터가 다음과 같다고 하자.

$A = (x_1, y_1)$

$B = (x_2, y_2)$

두 점 사이의 거리는 다음과 같다.

$$d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

이 공식은 피타고라스 정리를 이용한 거리 계산이다.

예를 들어 $A=(1,2)$, $B=(4,6)$ 이라면 x 축 차이는 3 이고 y 축 차이는 4 이다.

$$\begin{aligned}x \text{ 차이} &= 4 - 1 = 3 \\y \text{ 차이} &= 6 - 2 = 4 \\거리 &= \sqrt{(3^2 + 4^2)} \\&= \sqrt{(9 + 16)} \\&= \sqrt{25} \\&= 5\end{aligned}$$

즉 두 점 사이의 거리는 5 이다.

특성이 2 개가 아니라 여러 개일 때는 다음과 같이 확장된다.

$$d(x, y) = \sqrt{\sum_{j=1}^m (x_j - y_j)^2}$$

여기서 m 은 특성의 개수이다.

예를 들어 Iris 데이터셋처럼 특성이 4 개라면 4 개 특성의 차이를 각각 제공하고 모두 더한 뒤 제곱근을 구한다.

3. K-Means 클러스터링

K-Means 는 가장 대표적인 클러스터링 알고리즘이다.

K-Means 에서 K 는 군집의 개수를 의미한다.

예를 들어 $K=3$ 이면 데이터를 3 개의 그룹으로 나눈다.

K-Means 의 기본 과정은 다음과 같다.

1. 군집 개수 K 를 정한다.
2. K 개의 중심점, 즉 centroid 를 임의로 선택한다.
3. 각 데이터를 가장 가까운 중심점에 배정한다.
4. 각 군집에 속한 데이터들의 평균을 계산하여 중심점을 새로 갱신한다.
5. 중심점이 거의 변하지 않을 때까지 3~4 단계를 반복한다.

4. K-Means 의 중심점 계산 공식

군집 중심점은 해당 군집에 속한 데이터들의 평균이다.

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

여기서 μ_k 는 k 번째 군집의 중심점이고, C_k 는 k 번째 군집에 속한 데이터들의 집합이다.
 $|C_k|$ 는 그 군집에 들어 있는 데이터 개수이다.

예를 들어 어떤 군집에 다음 세 개의 데이터가 있다고 하자.

$$A = (2, 4)$$

$$B = (4, 6)$$

$$C = (6, 8)$$

중심점은 각 좌표의 평균이다.

$$x \text{ 평균} = (2 + 4 + 6) / 3 = 4$$

$$y \text{ 평균} = (4 + 6 + 8) / 3 = 6$$

따라서 중심점은 다음과 같다.

$$\text{중심점} = (4, 6)$$

즉 K-Means 는 각 군집의 평균 위치를 계속 다시 계산하면서 군집을 안정화한다.

5. K-Means 의 목적 함수

K-Means 는 각 데이터가 자신이 속한 군집 중심점과 최대한 가깝도록 만드는 것이 목표이다.

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

이 식에서 J 는 전체 오차이다. x_i 는 하나의 데이터이고, μ_k 는 해당 데이터가 속한 군집의 중심점이다. $\|x_i - \mu_k\|^2$ 는 데이터와 중심점 사이의 거리 제곱이다.

이 공식의 의미는 다음과 같다.

각 데이터와 자기 군집 중심점 사이의 거리 계산

→ 거리를 제곱

→ 같은 군집 안의 거리들을 모두 더함

→ 모든 군집에 대해 다시 더함

K-Means 는 이 값 J 를 작게 만드는 방향으로 중심점을 이동시킨다. J 가 작다는 것은 각 데이터가 자기 군집 중심점 가까이에 모여 있다는 뜻이다. 따라서 군집이 잘 형성되었다고 볼 수 있다.

6. 간단한 K-Means 계산 예시

다음 데이터가 있다고 하자.

$$A = (1, 1)$$

$$B = (2, 1)$$

$$C = (8, 8)$$

$$D = (9, 8)$$

군집 개수는 $K=2$ 라고 하자.

초기 중심점을 다음과 같이 정한다.

$$\text{중심점 1} = A = (1, 1)$$

$$\text{중심점 2} = C = (8, 8)$$

각 데이터를 가까운 중심점에 배정한다.

A 는 중심점 1 과 거리가 0 이므로 군집 1 이다.

B 와 중심점 1 의 거리:

$$B = (2, 1), \text{중심점 1} = (1, 1)$$

$$\text{거리} = \sqrt{(2-1)^2 + (1-1)^2}$$

$$= \sqrt{1^2 + 0^2}$$

$$= 1$$

B 와 중심점 2 의 거리:

$$B = (2, 1), \text{ 중심점 } 2 = (8, 8)$$

$$\begin{aligned}\text{거리} &= \sqrt{(8-2)^2 + (8-1)^2} \\ &= \sqrt{36 + 49} \\ &= \sqrt{85} \\ &\approx 9.22\end{aligned}$$

B 는 중심점 1 에 더 가까우므로 군집 1 에 배정된다.

C 와 D 는 중심점 2 에 더 가깝기 때문에 군집 2 에 배정된다.

결과는 다음과 같다.

$$\text{군집 } 1 = \{A, B\}$$

$$\text{군집 } 2 = \{C, D\}$$

새로운 중심점은 평균으로 계산한다.

$$\begin{aligned}\text{군집 } 1 \text{ 중심점} &= ((1+2)/2, (1+1)/2) \\ &= (1.5, 1)\end{aligned}$$

$$\begin{aligned}\text{군집 } 2 \text{ 중심점} &= ((8+9)/2, (8+8)/2) \\ &= (8.5, 8)\end{aligned}$$

이후 다시 거리를 계산하고 배정한다. 더 이상 배정 결과가 변하지 않으면 학습이 종료된다.

7. 계층적 클러스터링

계층적 클러스터링은 데이터를 단계적으로 묶어 나가는 방식이다. 결과는 보통 트리 형태의 **덴드로그램(Dendrogram)** 으로 표현된다.

가장 많이 사용하는 방식은 병합형 계층적 클러스터링이다. 처음에는 모든 데이터가 각각 하나의 군집이다. 이후 가장 가까운 군집끼리 계속 합친다.

초기 상태:

$\{A\}, \{B\}, \{C\}, \{D\}$

1 단계:

$\{A,B\}, \{C\}, \{D\}$

2 단계:

$\{A,B\}, \{C,D\}$

3 단계:

$\{A,B,C,D\}$

이 방식은 군집 개수를 처음부터 정하지 않아도 데이터가 어떤 계층 구조로 묶이는지 확인할 수 있다는 장점이 있다.

8. 계층적 클러스터링의 거리 기준

군집 간 거리를 계산하는 방법은 여러 가지가 있다.

단일 연결법

두 군집 사이에서 가장 가까운 데이터끼리의 거리 사용

$$D(C_a, C_b) = \min_{x \in C_a, y \in C_b} d(x, y)$$

이 방식은 가까운 점 하나만 있어도 두 군집이 가깝다고 판단한다. 긴 사슬 모양의 군집이 생길 수 있다.

완전 연결법

두 군집 사이에서 가장 먼 데이터끼리의 거리 사용

$$D(C_a, C_b) = \max_{x \in C_a, y \in C_b} d(x, y)$$

이 방식은 군집 전체가 서로 가까워야 병합되므로 비교적 조밀한 군집을 만든다.

평균 연결법

두 군집에 속한 모든 데이터 쌍의 거리 평균 사용

$$D(C_a, C_b) = \frac{1}{|C_a||C_b|} \sum_{x \in C_a} \sum_{y \in C_b} d(x, y)$$

이 방식은 단일 연결법과 완전 연결법의 중간 성격을 가진다.

9. DBSCAN 클러스터링

DBSCAN은 밀도 기반 클러스터링 알고리즘이다. K-Means 처럼 군집 개수를 미리 정하지 않아도 된다.

대신 두 가지 기준을 사용한다.

eps: 반경

min_samples: 반경 안에 있어야 하는 최소 데이터 개수

DBSCAN은 어떤 점 주변에 데이터가 충분히 많으면 그 지역을 하나의 군집으로 본다.

10. DBSCAN의 핵심 개념

핵심점(Core Point)

어떤 점을 기준으로 반경 eps 안에 min_samples 개 이상의 데이터가 있으면 핵심점이다.

경계점(Border Point)

자기 주변에는 데이터가 충분하지 않지만, 핵심점의 반경 안에 포함되는 점이다.

잡음점(Noise Point)

어떤 군집에도 속하지 않는 이상치 데이터이다.

11. DBSCAN 의 이웃 집합 공식

$$N_{eps}(p) = \{q \in D \mid d(p, q) \leq eps\}$$

이 공식은 점 p 를 기준으로 거리 eps 안에 들어오는 모든 점들의 집합을 의미한다.

예를 들어 $eps=2$ 라고 하자. 점 p 주변 2 이하의 거리에 있는 데이터가 5 개이고, $min_samples=4$ 라면 p 는 핵심점이다. 반대로 주변 데이터가 2 개뿐이면 핵심점이 아니다.

DBSCAN 은 이런 핵심점들을 연결하면서 군집을 확장한다.

12. K-Means, 계층적 클러스터링, DBSCAN 비교

알고리즘	기준	군집 개수 지정	이상치 처리	특징
K-Means	중심점 거리	필요	약함	빠르고 단순함
계층적 클러스터링	군집 간 거리	선택 가능	보통	계층 구조 확인 가능
DBSCAN	밀도	불필요	강함	이상치 탐지 가능

13. 클러스터링 평가 지표

클러스터링은 정답이 없는 경우가 많기 때문에 평가가 쉽지 않다. 대표적인 내부 평가 지표로 **실루엣 계수(Silhouette Score)** 가 있다.

실루엣 계수는 한 데이터가 자기 군집에는 얼마나 잘 속해 있고, 다른 군집과는 얼마나 떨어져 있는지를 측정한다.

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

여기서 $a(i)$ 는 데이터 i 와 같은 군집에 속한 다른 데이터들과의 평균 거리이다. 즉 자기 군집 안에서 얼마나 가까운지를 의미한다.

$b(i)$ 는 데이터 i 가 속하지 않은 다른 군집 중 가장 가까운 군집과의 평균 거리이다.

해석은 다음과 같다.

$s(i)$ 가 1에 가까움:

자기 군집과 가깝고 다른 군집과 멀다. 좋은 군집이다.

$s(i)$ 가 0에 가까움:

두 군집의 경계에 있다.

$s(i)$ 가 -1에 가까움:

다른 군집에 더 가까우므로 잘못 배정되었을 가능성이 있다.

예를 들어 어떤 데이터의 값이 다음과 같다고 하자.

$$a(i) = 2$$

$$b(i) = 6$$

그러면 실루엣 계수는 다음과 같다.

$$\begin{aligned} s(i) &= (6 - 2) / \max(2, 6) \\ &= 4 / 6 \\ &= 0.67 \end{aligned}$$

0.67은 비교적 좋은 군집 배정이라고 볼 수 있다.

14. 클러스터링에서 표준화가 중요한 이유

클러스터링은 거리 계산을 기반으로 하기 때문에 특성의 단위가 다르면 결과가 왜곡될 수 있다.


예를 들어 다음 두 특성이 있다고 하자.

나이: 20 ~ 70

연봉: 20,000,000 ~ 100,000,000

이 경우 거리 계산에서 연봉 값이 너무 크기 때문에 나이보다 연봉이 훨씬 큰 영향을 준다. 따라서 보통 클러스터링 전에는 표준화를 수행한다.

표준화 공식은 다음과 같다.



여기서 x 는 원래 값, μ 는 평균, σ 는 표준편차이다.

예를 들어 어떤 특성의 평균이 50 이고 표준편차가 10 일 때, 값이 70 이면 표준화 값은 다음과 같다.

$$\begin{aligned} z &= (70 - 50) / 10 \\ &= 20 / 10 \\ &= 2 \end{aligned}$$

즉 평균보다 표준편차 2 개만큼 높은 값이라는 뜻이다.

표준화를 하면 모든 특성이 비슷한 스케일을 가지므로 거리 기반 클러스터링이 더 안정적으로 작동한다.

15. 클러스터링의 활용 분야

클러스터링은 다양한 분야에서 사용된다.

고객 분석에서는 비슷한 구매 패턴을 가진 고객을 묶어 VIP 고객, 가격 민감 고객, 신규 고객 등으로 구분할 수 있다. 마케팅에서는 각 고객군에 맞는 쿠폰이나 추천 상품을 제공할 수 있다.

이미지 분석에서는 비슷한 색상이나 패턴을 가진 픽셀을 묶어 이미지 분할에 사용할 수 있다.

문서 분석에서는 비슷한 주제를 가진 문서를 자동으로 그룹화할 수 있다. 제조 분야에서는 센서 데이터 패턴을 분석하여 정상 작동 그룹과 이상 작동 그룹을 구분할 수 있다.

클러스터링은 정답이 없는 데이터에서 비슷한 데이터끼리 자동으로 묶는 비지도학습 기법이다. 대표 알고리즘으로는 K-Means, 계층적 클러스터링, DBSCAN 이 있다.

K-Means 는 중심점과 거리 기반으로 빠르게 군집을 만들고, 계층적 클러스터링은 데이터가 단계적으로 묶이는 구조를 보여주며, DBSCAN 은 밀도 기반으로 군집을 찾고 이상치까지 탐지할 수 있다.

클러스터링에서 가장 중요한 개념은 거리 계산, 중심점 계산, 군집 내 오차 최소화, 밀도 판단, 평가 지표이다. 특히 K-Means 는 데이터와 중심점 사이의 거리 제곱합을 최소화하는 방식으로 작동하며, DBSCAN 은 일정 반경 안에 충분한 데이터가 존재하는지를 기준으로 군집을 만든다.

실무에서는 클러스터링 전에 반드시 표준화를 수행하고, 군집 결과를 시각화하거나 실루엣 계수로 평가하여 군집의 품질을 확인하는 것이 중요하다.