

교과목 2 : 데이터 분석과 머신러닝 / 딥러닝

단원 2 : 머신러닝

DAY3. 머신러닝 서포트벡터머신 구조

목 차


1. 지도학습 분류 알고리즘		3
2. 서포트 벡터 머신 알고리즘		8
3. 최근접 이웃(KNN) 알고리즘		17
4. 나이브 베이즈 알고리즘		28

1. 지도학습 분류 알고리즘

머신러닝(Machine Learning) 구조

Machine Learning 은 데이터를 이용하여 컴퓨터가 스스로 패턴을 학습하고 예측하도록 만드는 기술이다.

1. 머신러닝 전체 구조



2. 지도학습(Supervised Learning)

정답(Label)이 있는 데이터를 학습한다.

예:

공부시간	합격여부
2시간	불합격
8시간	합격

목적:

- 입력(X) → 정답(Y) 예측

지도학습 종류

종류	목적
분류(Classification)	카테고리 예측
회귀(Regression)	숫자 예측

3. 분류(Classification)

정답이 범주형(Category)인 문제 해결 방법이다.

예:

- 스팸 / 정상
- 고양이 / 개
- 암 / 정상

4. 대표 지도학습 분류 알고리즘

(1) Logistic Regression

확률 기반 분류 알고리즘이다.

출력값:

- 0~1 확률

예:

- 스팸일 확률 0.92

시그모이드 함수 사용

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

출력:

- 0~1 범위

특징

장점 빠름, 해석 쉬움

단점 복잡한 비선형 한계

(2) KNN (K-Nearest Neighbors)

가장 가까운 K개의 데이터를 보고 분류한다.

예:

- 주변 5개 중 4개가 고양이
→ 고양이 분류

거리 계산

유클리드 거리 사용

$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

특징

장점	단점
직관적	데이터 많으면 느림
구현 쉬움	스케일 영향 큼

(3) Naive Bayes (나이브 베이즈)

베이즈 정리를 이용한 확률 기반 분류 알고리즘이다.

특징:

- feature들이 서로 독립이라고 가정

베이즈 정리

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$P(A)$ 0.20

$P(B | A)$ 0.85

$P(B | \neg A)$ 0.10

$$P(A | B) = \frac{P(B|A)P(A)}{P(B)} \approx 0.68, P(B) \approx 0.25$$

특징

장점	단점
속도 빠름	독립 가정 비현실적
텍스트 분류 강함	복잡 패턴 한계

(4) Decision Tree (의사결정 트리)

질문을 반복하면서 데이터를 분류하는 트리 구조

예:

나이 > 30?

├─ YES → 구매

└─ NO → 미구매

특징

장점	단점
해석 쉬움	과적합 쉬움
시각화 가능	데이터 변화 민감

(5) Random Forest

여러 개의 Decision Tree를 생성하여 투표로 결정한다. (앙상블)

특징

장점	단점
성능 우수	모델 큼
과적합 감소	해석 어려움

(6) SVM (서포트 벡터 머신, Support Vector Machine)

두 클래스를 가장 잘 나누는 경계(초평면)를 찾는다.

핵심:

- 마진 최대화

초평면(분류 경계선)

$$w^T x + b = 0$$

특징

장점	단점
고차원 강함	속도 느림
일반화 우수	튜닝 어려움

(7) Neural Network (ANN : Artificial Neural Network)

인간 신경망을 모방한 모델이다.

구조:

- 입력층
- 은닉층
- 출력층

특징

장점	단점
복잡 패턴 학습	데이터 많이 필요
높은 성능	학습 비용 큼

5. 분류 알고리즘 비교

알고리즘	핵심 방식	특징
Logistic Regression	확률	단순, 빠름
KNN	거리 기반	직관적
Naive Bayes	확률 기반	텍스트 강함
Decision Tree	규칙 기반	해석 쉬움
Random Forest	앙상블	성능 우수
SVM	경계 최대화	고차원 강함
Neural Network	신경망	복잡 패턴 학습

2. 서포트 벡터 머신 알고리즘

초평면을 이용하여 데이터 분류하기

1. 서포트 벡터 머신의 이해

1) 서포트 벡터(support vector)

- 서포트 벡터 : 다차원 공간에 표현되는 점들 간의 경계 표면
- SVM(Support Vector Machine)의 목표
 - * 공간으로 구분
 - * 초평면 구조 : 양쪽을 균등하게 분할 생성
 - * 평평한 경계 생성

2) SVM(Support Vector Machine) 패턴의 활용 분야


- 의료 분야
 - * 암 또는 다른 유전병의 구별
- 생체 정보학 분야
 - * 마이크로어레이(microarray) 유전자 발현 데이터로 분류
- 텍스트 범주화
 - * 문서 속의 언어 식별 또는 주제별 문서 분류 등
- 핵심적인 사건 탐지
 - * 연소 엔진의 고장, 보안 결함 또는 지진 등

초평면을 이용하여 데이터 분류하기

2. 서포트 벡터 머신의 분류

1) 초평면을 이용한 분류


- SVM(Support Vector Machine)
 - * 초평면 경계 데이터의 유사한 클래스 값으로 그룹 분할
 - * 정사각형과 원 : 직선 또는 평면으로 분리 → 선형적인 분리 가능
 - * 점이 선형적으로 분리하기 어렵다는 문제로 확장
 - * 2차원 측면에서의 SVM 알고리즘 작업 → 두 클래스로 구분하여 직선 검색
- 3개의 후보 알고리즘
 - * 최대 마진의 초평면(Maximum Margin Hyperplane) : 컨벡스 헐 사이에서 가장 단거리 직선의 수직 이등분선
 - * 모든 데이터 포인트의 정확한 분리
 - * 임의의 노이즈가 추가되더라도 각 클래스의 경계 영역에 남음
- 서포트 벡터
 - * 각 클래스에서 MMH에 가장 근접한 점
 - * SVM에서 특징의 개수가 많았을 때 서포트 벡터 분류 모델의 저장이 간단함
 - * 서포트 벡터(Support Vector)의 식별 알고리즘은 벡터 기하학 유형에 의존
- 2차원과 3차원 선형의 분리가 가능함



초평면을 이용하여 데이터 분류하기


1) 초평면을 이용한 분류

- 사각형과 원의 구분선에 따른 잠재선 중 3가지



2) 선형적으로 분리 가능한 데이터

- 클래스를 선형적으로 분리 가능할 경우 최대 마진을 찾는 방법이 쉬움
- MMH의 두 데이터 포인트 집합이 바깥 경계 위치에서 최대한 먼 거리에 위치
- 바깥 경계는 컨벡스 헐(Convex Hull)
- * 이차 최적화 기술의 정교한 컴퓨터 알고리즘은 최대 마진
 - * 대안 접근법 : 모든 초평면 공간을 탐색하여 점을 균등하게 그룹별로 구분
 - * 두 개의 평행 평면을 찾아가고 두 평면은 가능한 먼 거리에 위치함
- MMH 블록 다각형 사이에서 최단 경로 직교의 이분화




비선형 공간을 활용하여 커널 적용하기

1. 비선형 커널

1) 비선형 공간 커널

- 데이터 셋에서 변수 간의 관계 : 비선형적
- SVM의 주요 특징
 - * 커널 트릭 사용 문제 중 고차원 공간의 매핑 능력 포함
- 문제점
 - * 비선형 관계에서 갑자기 매우 선형적인 관계로 표시됨



〈잘못된 영역에 대한 점들의 비용 패널티〉

2) 비선형 공간 커널 사용

- 왼쪽의 산포도
 - * 날씨 클래스(맑음, 비 또는 눈)와 두 개의 특징(위도와 경도) 사이의 비선형적 관계
- 중심점 : 눈이 오는 snowy 클래스 멤버
- 외곽점 : 모두 sunny 클래스 멤버
- 커널 트릭이 적용됨
- 그림의 오른쪽 : 새로운 차원(고도)에 대한 인식으로 데이터 관측
- 클래스는 완벽히 선형적으로 분리됨
- 새로운 관점에 해당됨


비선형 공간을 활용하여 커널 적용하기

3) 비선형 공간 커널 SVM의 장점

- 분류 또는 숫자 예측 문제에 사용됨
- 노이즈에 영향을 받지 않음
- 과적합도 쉽게 발생되지 않음
- 신경망을 사용하는 것보다 쉬움
- SVM 알고리즘이 잘 지원됨
- 정확도가 높음

4) 비선형 공간 커널 SVM의 단점

- 최고의 모델을 찾을 경우 커널과 모델 파라미터의 조합 구성을 테스트 함
- 훈련이 느림
- 입력 데이터 셋의 특징 또는 예시가 많을 때 느림
- 해석하기 어려운 복잡한 블랙박스 모델 생성



〈커널 트릭을 활용하여 비선형 문제를 선형으로 변환〉

비선형 공간을 활용하여 커널 적용하기

2. SVM으로 OCR 수행하기

1) 픽셀 패턴 연결 관계

- 픽셀 패턴을 상위 개념으로 연결하는 관계
 - * 이미지 데이터는 노이즈가 잘 생김
 - * 방향, 조명, 피사체의 위치 등 이미지의 작은 변화 포착
 - * SVM : 이미지 데이터에 대한 문제 해결에 긍정적
 - * 노이즈에 민감하지 않도록 복잡한 패턴으로 학습 가능
 - * 높은 정확도로 시각적 패턴 인식

2) 1단계 : 분석 데이터 수집

- 데이터 셋
 - * 영어 알파벳 대문자 26개에 대한 20,000개의 예시
- 각 예시는 20개의 흑백 글꼴 : 무작위 모양으로 재생성시켜 왜곡 출력
- 왜곡 : 인간은 쉽게 인식하고 이해하지만 컴퓨터가 인식하기는 어려움



〈SVM(Support Vector Machine) 식별 서체〉

비선형 공간을 활용하여 커널 적용하기

3) 2단계 : 분석 데이터 탐색과 준비

- 프레이(pre)와 슬레이트(slate) 문서의 글리프(glyph)가 컴퓨터로 스캔 될 경우 픽셀
- 17개의 통계 속성
 - * 글리프의 가로와 세로 차원
 - * 흰색과 검정색 픽셀의 비율
 - * 검정색 픽셀 : 평균 가로와 세로 위치의 동일한 특성
 - * 다양한 영역에서의 검정색 픽셀 농도로 알파벳 26개 문자의 구별 방법 제공
- 머신러닝 훈련이 테스트 단계로 이동
- 훈련과 테스트 집합 간의 데이터는 무작위로 구분됨
- 프레이와 슬레이트의 데이터는 랜덤화됨
- 1단계 : 16,000 레코드(80%)로 모델 구축
- 2단계 : 4,000 레코드(20%)로 테스트 적용
- 훈련과 테스트 데이터프레임 사용

4) 3단계 : 분석 데이터 모델 훈련

- SVM모델의 적합 용도로 선택
- 'LIBSVM' 라이브러리 사용
- klaR 패키지 : SVM구현에 R 실행 함수 활용
- kernlab 패키지에 SVM 함수로 시작
- R로 사용자 정의형 모델 구현
- SVM 모델은 다양한 자동화 방식으로 훈련 평가

비선형 공간을 활용하여 커널 적용하기

5) 4단계 : 분석 모델 성능 평가

- predict() 함수 : 문자 분류 모델의 테스트 데이터 셋으로 예측
- 모델의 예측된 문자와 테스트 데이터 셋에 있는 실제 기존 문자와 일치 여부 확인
- 결과
 - * 테스트 레코드 4,000개 중 3,357 개의 문자 식별

6) 5단계 : 분석 모델 성능 개선

- OCR 소프트웨어 사용으로 단순한 모델에 대한 성과
 - * 84% 정확도
 - * 모델의 예측이 실제 값을 기적적인 운으로 적중할 확률 : 4% 미만
 - * 랜덤으로 선택된 모델에 비해 20배 정도 뛰어남
- SVM 커널 함수 변경
 - * 좀 더 복잡한 커널 함수를 활용해 데이터를 보다 높은 차원의 공간에서 매핑
 - * ksvm() 함수를 활용해 RBF 기반의 SVM 훈련
- 선형 SVM의 정확도 비교
- 결과
 - * 커널 함수를 변경하여 문자 인식 모델의 정확도를 84%에서 93%로 향상

비선형 공간을 활용하여 커널 적용하기

6) 5단계 : 분석 모델 성능 개선

- 모델의 훈련 데이터 : 과적합과 과소적합 간의 균형 조절
 - * 비용 값이 커질수록 모든 훈련 인스턴스의 정확한 분류가 어려움
 - * 훈련과 평가의 반복보다는 `sapply()` 함수 사용
 - * 비용 값의 벡터에 적합한 사용자 정의 함수 적용
 - * `seq()` 함수로 5~40까지 5단계씩 증가하는 벡터 생성
 - * 모델 훈련의 비용 값을 사용하고, 훈련 데이터셋 예측
 - * 각 모델의 정확도 = 실제값을 정확하게 맞춘 횟수 / 전체 예측
- 결과 : 93% 정확도
 - * SVM 비용 파라미터 $C = 1$ 은 9개의 평가 중에서 가장 낮은 정확도
 - * 상당한 성능 개선, 향상된 정확도
 - * 실생활에서 완벽한 모델의 가능성으로 시사

```
rbf_Same
  FALSE    TRUE
0.06875 0.93125
```


3. 최근접 이웃(KNN) 알고리즘

최근접 이웃으로 분류된 과정 이해하기

1. 최근접 이웃 분류의 이해

1) 최근접 이웃 분류의 의미

- 분류의 원리

- * 레이블이 없는 예시를 유사한 클래스로 할당 및 분류
- * 회상 능력 적용 : 현재의 결론을 위해 과거의 경험 적용

- k-NN 알고리즘 응용분야

- * 동영상 및 이미지에서 광학 글자 인식과 컴퓨터 비전(얼굴 인식) 응용
- * 각 개인에 따른 선호도 예측 추천 시스템(영화, 음악 등)
- * 단백질과 유전자데이터를 통한 패턴 인식(질병 등 건강 정보 발견 가능)

2) 최근접 이웃 분류의 필요성

- 현재 분석의 문제점

- * 일반적인 특징과 타깃 클래스 간의 관계가 복잡함
- * 이해가 어렵거나 유사한 클래스 유형의 아이템은 동질적인 경향으로 분류

- 최근접 이웃으로 구분의 필요성


- * 개념 정의가 어렵고 데이터에 노이즈가 많음
- * 그룹 간의 구분이 없음
- * 이웃 알고리즘의 클래스 경계를 식별하기 어려움

최근접 이웃으로 분류된 과정 이해하기

2. k-NN 알고리즘

1) 분류를 위한 최근접 이웃 방법

- k-최근접 이웃(k-NN, k-nearest neighbors) 알고리즘
- 단순한 머신러닝 알고리즘이며 광범위하게 사용됨



〈음식의 바삭함과 단맛 정도의 산포도〉

2) k-NN 알고리즘의 장단점


장점	단점
■ 단순하면서 효율적임	■ 모델 생성 없이 특징과 클래스 간 관계 이해 능력이 부족함
■ 기존 데이터 분포 영역의 영향을 받지 않음	■ 적합한 k의 선택 과정 필요
■ 훈련단계의 신속함	■ 분류 진행 단계가 느림
	■ 명목적인 특징과 누락된 데이터 용도의 추가적인 처리 필요

최근접 이웃으로 분류된 과정 이해하기

3) k-NN 알고리즘 분류

◦ k-최근접 이웃 정보

- * k-최근접 이웃 정보 데이터를 활용하여 레이블이 없는 예시를 분류함
- * 문자 k : 최근접 이웃 개수의 임의의 사용을 허용하는 의미의 변수 항목
- * k의 선택 알고리즘
 - 여러 범주로 분류
 - 명목 변수 레이블로 훈련된 데이터 셋이 필요함
 - k-NN 테스트 데이터 셋에 레이블이 없는 경우 훈련 데이터의 유사도를 기준으로 함
 - '가장 근접한' k개의 레코드 검색
 - 레이블이 없는 테스트 인스턴스(instance)는 k개의 최근접 이웃이 많은 클래스에 배정



〈비슷한 속성의 음식 경향〉


◦ 거리로 유사도를 측정하는 방식

- * 최근접 이웃을 검색할 때, 거리 함수(distance function) 또는 두 인스턴스 사이의 유사도 측정
- * 거리 계산식의 다양한 접근 방법 존재
- * 전통적인 k-NN 알고리즘은 유클리드 거리(Euclidean distance)를 활용함

최근접 이웃으로 분류된 과정 이해하기

4) 적절한 k 선택

- k-NN 이웃의 개수
 - * 모델의 미래 데이터에 대한 일반적인 능력 결정
- 훈련 데이터의 과대적합(overfitting)과 과소적합(underfitting) 사이의 균형
 - * 편향 분산 트레이드오프(bias-variance tradeoff) 문제
- 편향 분산 트레이드오프(bias-variance tradeoff) 문제
 - * 노이즈가 많은 데이터로 인해 영향 또는 분산 감소
- 작은 값으로 중요한 패턴이 무시됨
 - * 위험한 학습자의 편향으로 봄
- k가 작아질수록 편향 증가, 분산 감소



- 훈련 데이터의 관측
 - * 모든 훈련 인스턴스에 대한 최종 투표
 - * 가장 보편적인 클래스는 대다수의 투표자
 - * 훈련 데이터 모델 : 최근접 이웃과 무관하게 대부분의 클래스 예측
 - * 한 개의 최근접 이웃 적용 : 노이즈가 있는 데이터나 이상치가 예시의 분류에서는 큰 영향을 끼치게 됨

최근접 이웃으로 분류된 과정 이해하기

5) 최적의 k값 존재

- 두 극단 데이터 사이의 어느 위치에 존재함
- 일반적인 점선으로 표시된 결정 경계(k값의 크기에 따라 받는 영향이 달라짐)
- 값이 커질수록 변화됨
 - * 좀 더 복잡한 결정 경계를 그릴 수 있음
 - * 훈련 데이터의 세밀한 구조를 만들 수 있음
- 문제 : 직선 경계 또는 곡선 경계로 학습되어야 할 본질적인 개념 부족
- 최적의 k 정의 방법
 - * 다양한 테스트 데이터 셋을 준비하여 몇 개의 k 값을 테스트함
 - * 분류 성능이 최적화된 선택 방식 선택
 - * k 선택의 중요도 : 데이터 노이즈가 적고, 훈련 데이터 셋이 커질수록 k 선택의 중요도 감소
 - * 대량의 예시 데이터를 충분히 포함하므로 최근접 이웃 투표 가능

6) k-NN에 적합한 데이터 준비

- 일반적인 특징
 - * k-NN 알고리즘에 적용하기 위해 표준 범위로 변환
- 필요한 이유
 - * 거리 공식 측정 방법에 지나치게 의존적임
- 값의 범위가 다르게 된 특징
 - * 값의 범위가 클수록 거리 측정치는 큰 범위를 포함하는 특징에 따라 결정
- 스코빌 척도(Scoville scale) 측정
 - * 데이터 셋 추가 문제
 - * 데이터의 특징 재조정
 - * 각 특징이 거리 공식에 따라 상대적으로 동일함
 - * 기여하는 범위에 따라 축소 또는 확대

최근접 이웃으로 분류된 과정 이해하기

6) k-NN에 적합한 데이터 준비

- k-NN 재조정 방법
 - * 최소-최대 정규화(Min-max normalization, 전통적 방법)
 - 모든 데이터 값이 0과 1 사이의 범위에 포함됨
 - * Z-점수 표준화(z-score standardization)
 - 특징 x 에서 평균값을 빼고 그 수식 결과를 x 의 표준편차로 나누기하여 적용

7) k-NN 알고리즘이 게으른 이유

- 학습 정의의 엄격한 적용으로 게으른 학습자는 실제로 아무것도 학습하지 않음
- 훈련 데이터를 글자 그대로 저장만 함
- 훈련 단계가 매우 빠르게 일어나 실제 훈련 단계에서는 아무것도 훈련하지 않음
- k-NN 알고리즘의 단점
 - * 예측 단계가 훈련 단계와 비교했을 때 상대적으로 느린 경향이 있음
 - * 추상화된 모델보다 훈련 인스턴스에 지나치게 의존하는 이유
 - 게으른 학습은 인스턴스 기반 학습(instance-based learning)이나 암기 학습(rope learning)이기 때문
- 비모수 학습(non-parametric)
 - * 데이터 자체에 대해 학습하는 파라미터가 없음
 - * 분류기의 데이터 활용 방법을 이해하기 어렵기 때문에 기저 데이터에 대한 이론을 생성하지 않음
 - * 학습자의 패턴 검색 성향 : 잠재적인 함수 형태에 데이터를 적용하면 일반적인 패턴과 유사
- 머신러닝에서는 각각 다른 편향성을 지니고, 다른 결론을 도출함



실무 데이터 알고리즘의 진행 과정 및 성능

1. k-NN 알고리즘 데이터 분석

1) k-NN 알고리즘 데이터

- k-NN 알고리즘으로 유방암 진단

- * 머신러닝 암세포 식별의 자동화로 의료 시스템에 상당한 혜택을 줌
- * 과정의 자동화로 암세포 검출 단계의 효율성 향상
- * 의사가 진단 시간은 보다 적게 사용하고, 질병 치료 시간은 세밀하게 사용
- * 자동화된 검사 시스템으로 검사 단계에서 근원적으로 주관적인 평가 요소 제외
- * 높은 정확성 검출 : k-NN 알고리즘을 적용하여 암세포 발견에 대한 머신러닝의 유용성 여부 확인 가능

2) 1단계 : 분석 데이터 수집

- 유방암 진단 데이터

- * 각 예시 데이터의 32개 특징
 - 식별 번호와 암 진단 데이터
 - 30개의 수치로 평가된 실험실 측정치
 - 진단 : 악성은 'M', 양성은 'B'로 코드화
- * 30개의 측정치
 - 세포핵의 10개 특성에 대한 평균과 표준 오차, 최악의 값(최댓값)
- * 10개 특성
 - 질감, 반지름, 넓이, 매끄러움, 둘레, 오목함, 오목점, 조밀성, 대칭성, 프랙탈 차원(fractal dimension)

실무 데이터 알고리즘의 진행 과정 및 성능

3) 2단계 : 분석 데이터 탐색과 준비

- 변환 : 수치 데이터의 정규화
 - * 데이터 특징의 정규화
 - * `standardize()` 함수 생성 → 숫자 벡터 x 에 적용
 - * x 의 값에서 x 의 최솟값 빼기 → x 의 범위로 나누기 → 결과를 다시 벡터로 반환
- 데이터 준비 : 훈련 및 데이터 셋 생성
 - * 학습자의 레이블이 없는 상태에서 데이터 셋을 어느 정도로 잘 수행하는가?
 - 알려지지 않은 암 상태의 101개 후속 종양에 측정치 적용
 - 진단을 위한 머신러닝 예측 수준 정도 확인 가능

4) 3단계 : 분석 데이터 훈련

- 훈련 데이터와 레이블 벡터 유형으로 레코드 분류
- k-NN 알고리즘
 - * 훈련 단계에서 모델을 구축하지 않음
 - * k-NN과 동일한 게으른 학습자의 훈련 과정
 - * 입력 데이터는 구조화된 유형으로 저장
- 테스트 인스턴스 분류
 - * 분류에 적합한 기본 R 함수 제공
 - * `class` 패키지의 `k-NN()` 구현에 사용
- `knn()` 함수
 - * 테스트 데이터의 각 인스턴스 단위로 유클리드 거리 활용
 - * k-최근접 이웃 구조로 식별
 - * 'k'는 사용자 지정 숫자

실무 데이터 알고리즘의 진행 과정 및 성능

4) 3단계 : 분석 데이터 훈련

- 테스트 인스턴스
 - * k-최근접 이웃에 대한 투표로 분류
 - * 투표 결과가 동점일 경우 무작위 방법으로 한 개 선택
- 훈련 데이터 셋과 테스트 데이터 셋으로 분리
 - * 특징 : 각자 정확히 동일한 숫자를 지니고 있음
 - * 훈련 데이터의 레이블은 팩터와 벡터에 저장
 - * 파라미터 k는 투표에 참여하는 이웃 데이터의 개수로 지정

실무 데이터 알고리즘의 진행 과정 및 성능

2. k-NN 알고리즘 데이터 성능 평가

1) 4단계 : 분석 모델 성능 평가

○ 일치 평가

- * 벡터에 있는 실제 값과 얼마나 일치하는가를 평가함
- * gmodels 패키지의 CrossTable() 함수 활용
- * 예측과 실제 레이블 벡터 간의 일치 여부를 교차표로 생성

wisc_test_labels	wisc_test_pred		Row Total
	Benignant	Malevolent	
Benignant	62	0	62
	1.000	0.000	0.614
	0.939	0.000	
	0.614	0.000	
Malevolent	4	35	39
	0.103	0.897	0.386
	0.061	1.000	
	0.040	0.347	
Column Total	66	35	101
	0.653	0.347	

〈일치 평가(96% 정확도)〉

○ 실행 결과

- * 총 100개의 종양 중 4개(4%)
- * k-nn 방법 적용했을 때, 잘못된 분류
- * 96%의 실행 정확도
- * 오류 파악
 - 특히 위험한 FN
 - 성능 향상 필수
 - 부정확한 분류 값의 개수 감소 방법 파악
 - 지속적으로 모델의 반복 시도

실무 데이터 알고리즘의 진행 과정 및 성능

2) 5단계 : 분석 모델 성능 개선

◦ z-점수 표준화

* 두 가지 변형

- 첫 번째 수치 특징 재조정
- k에 몇 가지의 다른 값으로 시도

* 변환 : z-점수 표준화

- 거리를 계산할 경우 : 이상치에 좀 더 큰 가중치를 두는 것이 합리적
- z-점수 표준화로 예측 정확성 향상

* 실행 결과

- 이전 예시는 96%의 정확도이지만 z-점수 표준화 실행 결과 98% 정확도로 상승

```
# 훈련 집합과 테스트 집합으로 분류
wisc_train <- wisc_z[1:468, ]
wisc_test <- wisc_z[469:569, ]

# knn()로 집합으로 분류
# 테스트 단위로 재분류
wisc_test_pred <- knn(train = wisc_train, test =
wisc_test,
                      cl = wisc_train_labels, k = 5)

# 예측과 실제의 교차표 생성하기
CrossTable(x = wisc_test_labels, y = wisc_test_pred,
           prop.chisq = FALSE)
```

wisc_test_labels	wisc_test_pred		Row Total
	Benignant	Malevolent	
Benignant	62	0	62
	1.000	0.000	0.614
	0.954	0.000	
	0.604	0.000	
Malevolent	3	36	39
	0.077	0.923	0.386
	0.046	1.000	
	0.030	0.356	
Column Total	65	36	101
	0.644	0.356	

◦ k의 대체 값 테스트

* 정규화된 훈련 데이터 셋과 테스트 데이터 셋으로 구분

* 100개의 같은 레코드를 다수의 다른 k값으로 분류

* FN은 더 감소할 수 있음

◦ 접근 방법의 문제점 : 테스트 데이터의 가까운 정도 구분에 무리가 있음

◦ 환자 레코드 집합의 성능 : 성능 측정용 집합과 차이가 있을 수 있음

4. 나이브 베이즈 알고리즘

나이브 베이즈(NAIVE BAYES) 기법의 구조와 알고리즘

1. 나이브 베이즈의 기본 구조와 개념

1) 분류 문제의 베이즈 이론

- 수학자 토마스 베이즈(Thomas Bayes)의 연구에서 유래
 - * 사건의 확률과 추가 정보 필요
 - * 기본 원칙 : 확률이 어떻게 변화하는지 연구
 - * 사건(잠재적 결과)에 대해 복수 시행(사건이 발생할 가능성)
 - * 활용 증거를 기반으로 추정함

2) 베이지안 기법(Bayesian method)

- 사건과 실행
 - * 관측 데이터에서 사건이 일어날 확률 추정
 - * 통찰력 제공
 - * 확률의 이해를 위해 형식화가 필요함
 - * 아이디어로 만들어진 방법
 - * 보다 정교한 알고리즘으로 동일한 결과 도출
- 확률
 - * 0~1사이의 숫자로 사건의 발생할 가능성 표현
 - * 확률이 감소할수록 사건의 발생 가능성 감소
 - * 확률 0 : 사건의 발생 가능성 없음
 - * 확률 1 : 사건이 확실히 발생함
- 분류 분야
 - * 스팸 이메일 필터링 등의 텍스트 분류
 - * 컴퓨터 네트워크 침입 또는 비정상 행동 탐지
 - * 관찰된 상황이나 증상에 대한 의학적인 질병 진단

나이브 베이즈(NAIVE BAYES) 기법의 구조와 알고리즘

2) 베이지안 기법(Bayesian method)

- 베이지안 기법 분류기
 - * 훈련 데이터의 특징 값을 기반으로 결과가 관측될 확률 계산
 - * 분류기의 레이블이 없는 데이터에 적용
 - * 결과가 관측될 확률로 새로운 특징으로 강력한 클래스 예측
- 베이지안 기법 분류기의 결과
 - * 전체 확률을 추정함
 - * 다양한 속성 정보를 동시에 고려한 문제에 적합
 - * 머신러닝 알고리즘의 영향력이 약한 특징은 무시됨
 - 결과적으로 많은 영향 끼칠 수 있음

3) 베이지안 기법의 확률

- 확률의 이해
 - * 사건이 발생할 가능성
 - * 관측 데이터에서 사건 발생한 횟수를 전체 횟수로 나눈 값으로 추정
 - * 100개의 이메일 중에서 10개가 스팸일 경우 받은 메시지가 스팸일 확률 추정

$$10/100 = 0.1 (10\%)$$

- * $P(\text{스팸}) = 0.10$ 으로 표시 : 발생 가능한 확률 데이터
- * $P(\text{햄}) = 0.90$ 발생 가능성이 없는 확률 데이터
- * 가능한 모든 실행 결과 확률은 1로 합산
- * 동시 발생 가능성 없음
- * 유일성 있는 결과가 상호 배타적이면서 포괄적인 사건

나이브 베이즈(NAIVE BAYES) 기법의 구조와 알고리즘

3) 베이지안 기법의 확률

- 확률의 이해



<확률 공간은 스팸과 분할로 시각화>



<패턴의 식별 방법에 따른 종속된 시간>

나이브 베이즈(NAIVE BAYES) 기법의 구조와 알고리즘

1. 나이브 베이즈 알고리즘

1) 나이브 베이즈(Nalve Bayes) 알고리즘

- 분류 문제에 베이즈 이론을 적용하는 단순한 방법
- 베이저안 기법의 일반적인 알고리즘
- 표준 역할인 텍스트 분류에서 성공함
- 장점
 - * 보다 간단하고, 신속하여 효율적임
 - * 잡음과 누락된 데이터를 효율적으로 처리
 - * 훈련에는 비교적 적은 예시가 필요함
 - * 대용량의 예시에도 잘 작동함
 - * 예측용 추정 확률을 쉽게 얻음
- 단점
 - * 이메일 메시지의 스팸을 식별할 경우
 - A의 특징이 B의 특징보다 더 중요할 때 무시하고 계산함
 - 숫자 특징이 많은 데이터 셋에는 부적합
 - 추정된 확률의 예측 클래스보다 신뢰성이 부족함

2) 나이브 베이즈의 범주

- 특성
 - * 데이터의 학습 빈도표는 행렬로 구성
 - * 각 클래스와 특징 값의 조합으로 생성
 - * 자료형은 범주형에 해당함
 - * 숫자 특성 값의 범주가 없음
 - * 숫자 데이터로 작성하지 않음

나이브 베이즈(NAIVE BAYES) 기법의 구조와 알고리즘

2) 나이브 베이즈의 범주

- 숫자 특성
 - * 이산화, 빈(bins) 범주에 숫자를 포함함
 - * 이산화는 비닝(binning)이라 구분하여 칭함
 - * 나이브 베이즈 작업은 훈련 데이터가 대용량일 때 이상적


3) 나이브 베이즈의 이산화 특성

- 숫자 특성의 이산화 방법
 - * 데이터 분포에서 범주 또는 절단점 탐색
 - * 특정 시간의 이메일 발송 특징을 스팸 데이터 셋 구성에 추가
 - * 시간 데이터의 흐름을 히스토그램으로 표현
 - * 수치 데이터의 새 명목을 특징 레벨로 구분
 - * 스팸 발송자가 밤 늦은 시간에 실행
 - 이메일 확인 가능성이 높은 낮에 실행될 것으로 예상

나이브 베이즈(NAIVE BAYES) 기법의 구조와 알고리즘

4) 나이브 베이즈에서 유념할 특성

- 적은 데이터 범주의 수치 특성을 이산화 했을 때 정보 손실의 가능성이 있음
- 균형을 맞추는 것이 중요
- 빈의 개수가 적을수록 중요한 추세 감소



〈이메일 수신 분포의 시각화 히스토그램〉

- 빈의 개수
 - * 빈의 개수가 많을수록 나이브 베이즈 빈도표의 총계 감소
 - * 알고리즘의 노이즈 데이터 가능성 증가

알고리즘을 이용한 휴대폰 스팸 필터링

1. 스팸 필터링 알고리즘

1) 나이브 베이즈(Nalve Bayes) 스팸 필터링 알고리즘

- 기업은 SMS 스팸 문자 메시지 활용(SMS 스팸으로 잠재 고객의 타깃화)
- SMS 스팸의 필터링 분류 알고리즘 개발
- 이메일 스팸 필터링을 SMS 스팸에 적용
- SMS 메시지
 - * 160자 문자로 제한
 - * 메시지를 정크로 구분할 경우 사용되는 텍스트 양 감소
 - * 휴대폰의 속기 형태의 용어(합법적인 메시지와 스팸의 구분이 모호함)
 - * 나이브 베이즈 분류기로 문제점 처리

2) 1단계 : 분석 데이터 수집

- SMS 스팸 모음 데이터 사용
 - * 데이터 셋
 - SMS 메시지의 텍스트가 스팸 메시지와 함께 공존
 - * 정크 메시지
 - 스팸(spam) 레이블
 - 합법적인 메시지는 햄(ham) 레이블로 구분
 - * 스팸 메시지는 '무료' 빈도가 높음
 - * 햄 메시지는 '무료'일 가능성이 낮음
- 나이브 베이즈 분류기
 - * SMS 메시지가 스팸 또는 햄 프로파일에 적합한지 여부 판단
 - 단어 빈도의 패턴 활용

알고리즘을 이용한 휴대폰 스팸 필터링

3) 2단계 : 분석 데이터 탐색

◦ 분류기 구축

- * 첫 번째 단계 분석에 필요한 원시 데이터 처리
- * 텍스트 데이터는 단어와 문장을 컴퓨터 처리 가능한 형식으로 변환
- * 데이터 변환에 적합한 표현
- * 단어의 순서는 무시함
- * 단순히 단어의 출현 여부를 표시함(변수는 단어 주머니 big-of-words 사용)

◦ str() 함수 : 데이터프레임의 두 종류인 type과 text의 특징

◦ factor() 함수 : 문자를 벡터에서 팩터 형식으로 변환

◦ 텍스트 데이터 정리 및 표준화

- * SMS 메시지의 공백 단어, 숫자, 구두점 등 텍스트 문자열
- * 숫자와 구두점 제거 방법 필요(and, but, or : 중요도가 낮은 단어의 처리 방법)
- * 문장을 개별 단어로 구분하는 방법 필요
- * R의 'tm' 텍스트 마이닝 패키지 사용

◦ 텍스트 데이터 처리

- * VCorpus() 함수를 사용하여 텍스트 문서의 집합인 코퍼스(Corpus) 생성
- * 메모리에 저장하여 휘발성 있음
- * 코퍼스 문서에 컴퓨터, 데이터베이스 등 데이터의 출처 지정
- * SMS 텍스트 메시지
 - 기본 벡터에서 VectorSource() 리더 함수 활용하여 소스 객체 생성
 - VCorpus()에 제공
 - inspect() 함수를 통해 요약 결과 표시

알고리즘을 이용한 휴대폰 스팸 필터링

3) 2단계 : 분석 데이터 탐색

- 텍스트 문서의 용어 구분

- * 토큰화(tokenization) 과정
- * 토큰 : 텍스트 문자열의 한 요소 즉, 단어를 의미
- * 'TM' 패키지로 SMS 메시지 코퍼스를 토큰화 함
- * DocumentTermMatrix() 함수
 - 코퍼스의 문서 용어 행렬 데이터 구조 생성
 - 행은 문서(SMS 메시지), 열은 용어(단어)의 의미

- 훈련 및 테스트 데이터 셋 생성

- * 스팸 분류기를 구축하고 데이터로 평가 분석
- * 분류기는 데이터를 정리하고 처리된 이후에 분할 생성이 중요
- * 훈련 데이터 셋, 테스트 데이터 셋은 정확한 준비 단계 필요

- 텍스트 데이터의 시각화

- * 단어 구름(word cloud)
 - 텍스트 데이터의 단어 빈도를 시각적으로 표현
 - 구름 : 랜덤하게 흩어진 상태의 단어로 구성
 - 텍스트 중 빈도가 높은 단어는 더 큰 폰트로 표시
 - 일반적인 용어는 작은 폰트로 표시



〈SMS 메시지 단어 구름〉

알고리즘을 이용한 휴대폰 스팸 필터링

3) 2단계 : 분석 데이터 탐색

◦ 텍스트 데이터의 시각화

- * 유형의 그림 : 소셜 미디어 또는 웹 사이트에서 인기 있는 주제 관찰 방법 제공
- * wordcloud 패키지 : 단어 구름 다이어그램을 생성하도록, wordcloud() 함수 제공
- * 나이브 베이즈 스팸 필터의 성공 여부 판단에 활용
- * wordcloud() 함수를 제공하여 SMS 메시지의 단어 유형의 시각화

◦ 빈도가 높은 단어의 특성

- * 데이터 준비의 최종 단계로 희소 행렬은 나이브 베이즈 분류기 훈련 구조를 변환함
- * 특징 : SMS 메시지의 모든 단어에 대한 특징
- * 특징의 개수를 다섯 개 이하의 메시지로 제한
- * 훈련 데이터에서 약 0.1% 레코드보다 적은 단어 삭제

◦ 함수

- * findFreqTerms() 함수 : 빈도 높은 단어 검색
- * DTM을 받아 최소 횟수를 표시하는 단어를 문자 벡터로 반환



〈SMS 스팸과 햄 메시지 단어 구름〉

알고리즘을 이용한 휴대폰 스팸 필터링

2. 스팸 필터링 알고리즘의 훈련 및 개선

1) 3단계 : 분석 모델 훈련

- SMS 메시지
 - * 통계 모델 표현 형식으로 변환함
 - * 나이브 베이즈 알고리즘 적용
 - * SMS 메시지의 스팸 확률 추정에 적합한 단어의 존재 여부

2) 4단계 : 분석 데이터 모델 성능 평가

- SMS 분류기 평가
 - * 테스트 데이터의 메시지 예측 테스트 필요
 - * 분류기로 예측 생성
 - * 예측된 값과 실제 값의 차이 비교(예측 함수 : predict() 함수)
- 나이브 베이즈의 텍스트 분류
 - * 스팸 필터로 인한 중요한 문자 메시지 삭제 가능성
 - * 고성능을 위한 모델 변경 가능 여부 확인
- 분석 결과

Cell Contents			
			N
N / Table Total			
Total Observations in Table: 1389			
predicted \ actual	ham	spam	Row Total
ham	1200 0.864	28 0.020	1228
spam	6 0.004	155 0.112	161
Column Total	1206	183	1389

- * 1389개 SMS 메시지 중 34(6+28)개는 부정확하게 분류
- * 1206개의 햄 메시지 중 6개가 스팸으로 분류
- * 183개 스팸 메시지 중 28개가 햄으로 분류
- * 6개의 합법적인 메시지가 스팸으로 분류됨

알고리즘을 이용한 휴대폰 스팸 필터링

3) 5단계 : 분석 데이터 모델 개선

- 모델 훈련에서 라플라스 추정량을 설정하지 않음
- 스팸 메시지, 햄 메시지가 없는 단어는 분류 과정에서 결과 출력
- 최종적인 단계에서 예측된 클래스와 실제 분류의 교차표를 활용해 차이 비교

* FP(오류로 인해 스팸으로 분류된 햄 메시지)의 개수 : 6개에서 4개로 감소

* FN 개수가 28개에서 26개로 감소

Cell Contents					Cell Contents				
				N					N
				N / Table Total					N / Table Total
Total Observations in Table: 1389					Total Observations in Table: 1389				
predicted	actual	ham	spam	Row Total	predicted	actual	ham	spam	Row Total
ham	1200	28		1228	ham	1206	26		1232
	0.864	0.020				0.865	0.019		
spam	6			6	spam	4	157		161
	0.004	0.112				0.003	0.113		
Column Total	1206	183	1389		Column Total	1206	183	1389	

◦ 결론 요약

- * 모델의 정확도 검증
- * 균형을 유지하려면 모델을 대규모로 조정하기 전에 신중해야 함
- * 사용자는 스팸 메시지가 필터에서 적게 통과되는 것을 선호함
- * 햄 메시지의 과다한 필터링보다는 스팸 메시지의 필터링을 적게 나오게 할 필요성이 있음